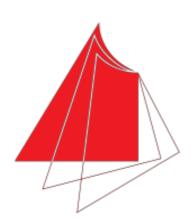
Big Data Engineering

Konstruktion datenintensiver Systeme

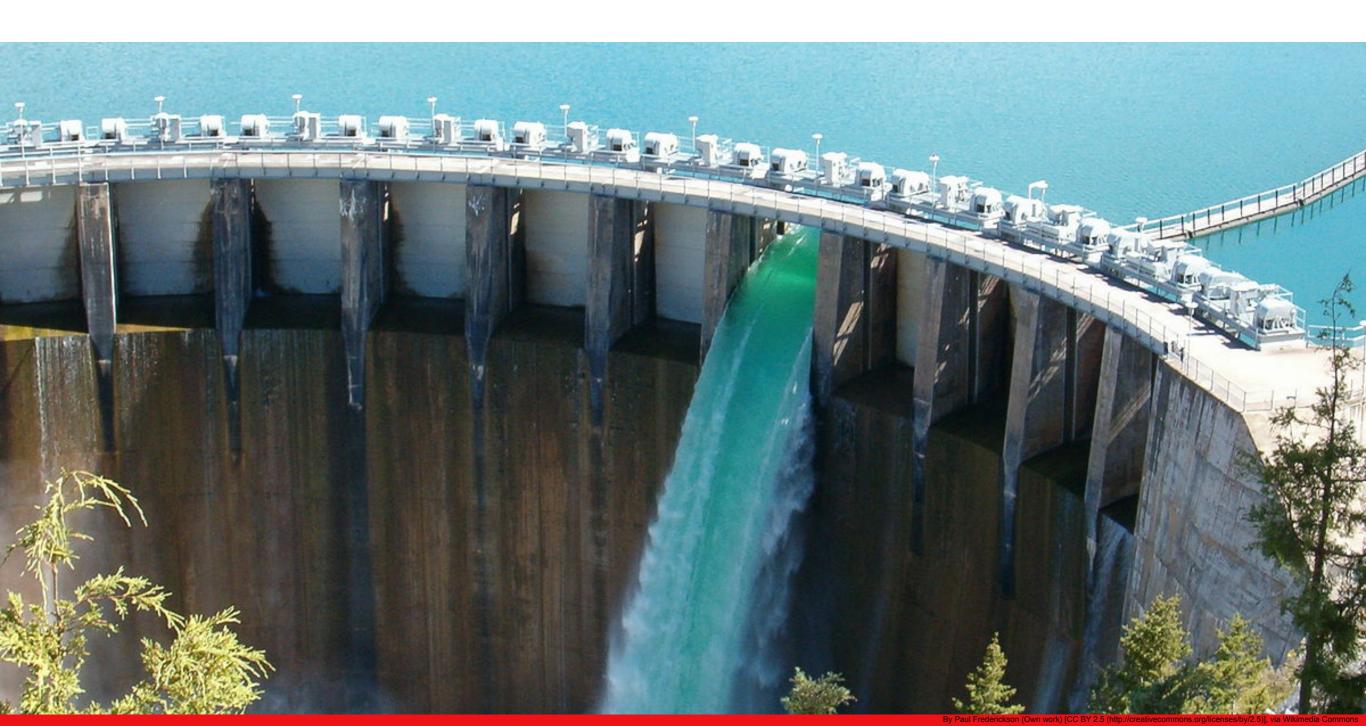
christian.zirpins@hs-karlsruhe.de

Big Data Modellierung



Hochschule Karlsruhe Technik und Wirtschaft

UNIVERSITY OF APPLIED SCIENCES





BDE-Termine — Winter 2018

#	KW	Termin	Block	Thema	Raum
	40	8.10.			
1	41	15.10.		Big Data Paradigma	Hörsaal
2	42	22.10.	Batch Layer	Big Data Modellierung	Hörsaal
3	43	29.10.		Big Data Speicherung	Hörsaal
4	44	5.11.		Übung: Hadoop DFS/Thrift	Labor
5	45	12.11.		Batch Verarbeitung	Hörsaal
6	46	19.11.		Übung: Hadoop Map Reduce	Labor
7	47	26.11.	Serving Layer	Big Data Bereitstellung	Hörsaal
8	48	3.12.		Übung: Cascalog	Labor
9	49	10.12.	Speed Layer	Big Data in Echtzeit	Hörsaal
10	50	17.12.		Queues und Stream Verarbeitung	Hörsaal
	51	24.12.			
	52	31.12.			
11	1	7.1.		Übung: Apache Kafka/Storm	Labor
12	2	14.1.		Micro-Batch Stream Verarbeitung	Hörsaal
13	3	21.1.		Lambda Architektur	Hörsaal
14	4	28.1.		Outro / Q&A / Abgabe	Labor

Raumplan

Hörsaal	E 303		
Labor	LI137		



Kurzer Rückblick



Themen der letzten Vorlesung

- Der Big Data Begriff
- Grenzen der Skalierbarkeit: Web Analytics mit klassischer DB
- Noch mal ganz von vorn: Was sind eigentlich Datensysteme?
- Die Lambda Architektur: Ein Paradigma für Big Data
- Big Data Technologien und Open Source Projekte



Datensysteme berechnen Funktionen über Daten

Ein **Datensystem** beantwortet Fragen basieren auf Informationen, die in der Vergangenheit bis in die Gegenwart erworben wurden.

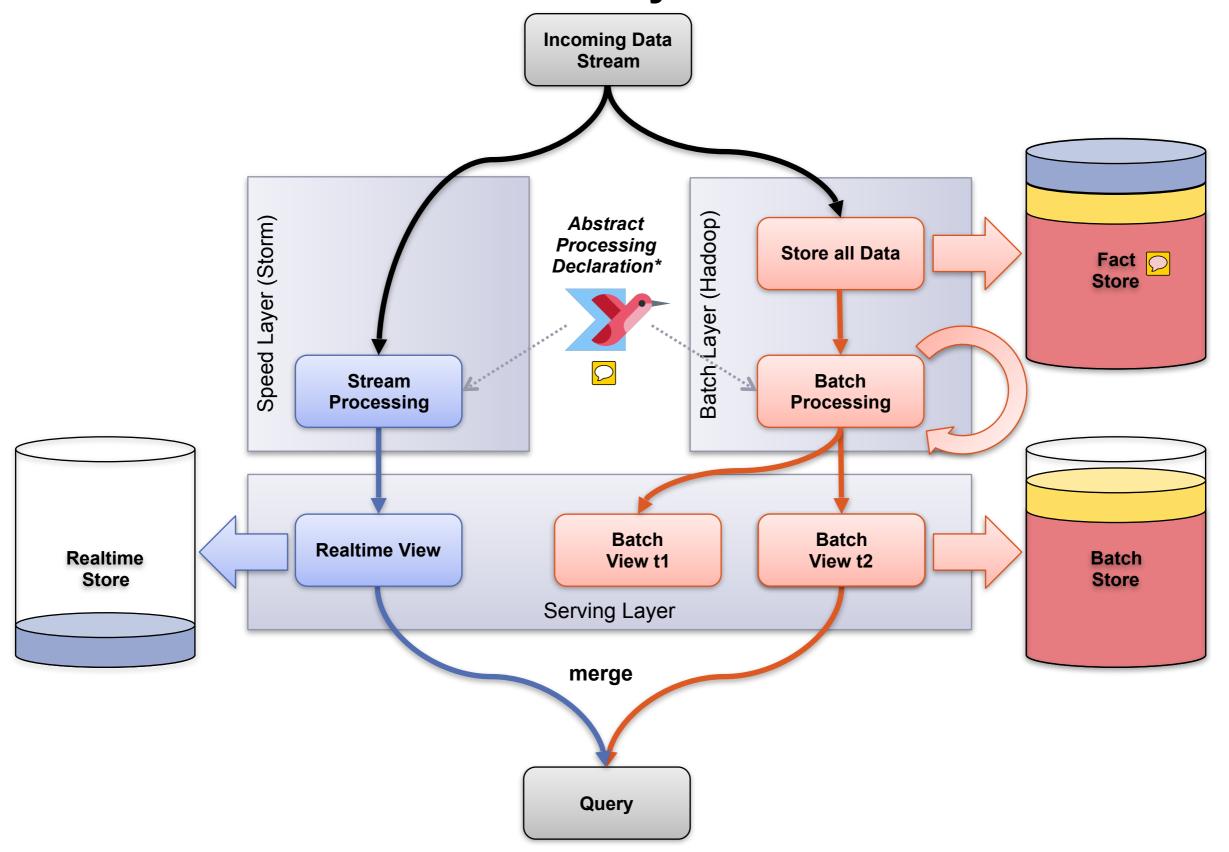
Query = Funktion (Datenraum)

```
batch view = function(all data)
realtime view = function(realtime view, new data)
query = function(batch view, realtime view)
```

Komplette Lambda Architektur als Gleichungssystem



Lambda Architektur für Datensysteme





Lernziele



Nach dieser Vorlesung können Sie...

die wichtigsten Eigenschaften von Daten einordnen

- \bigcirc
- erklären, wie das Konzept eines faktenbasierten Datenmodells die Eigenschaften von Daten bewahrt
- die Struktur eines faktenbasierten Datenmodells durch Graph
 Schemas ausdrücken
- Graph Schemas mit Thrift IDL spezifizieren



Die Eigenschaften von Daten



Einige Begriffe

Information ist die allgemeine Wissensbasis im Big Data System

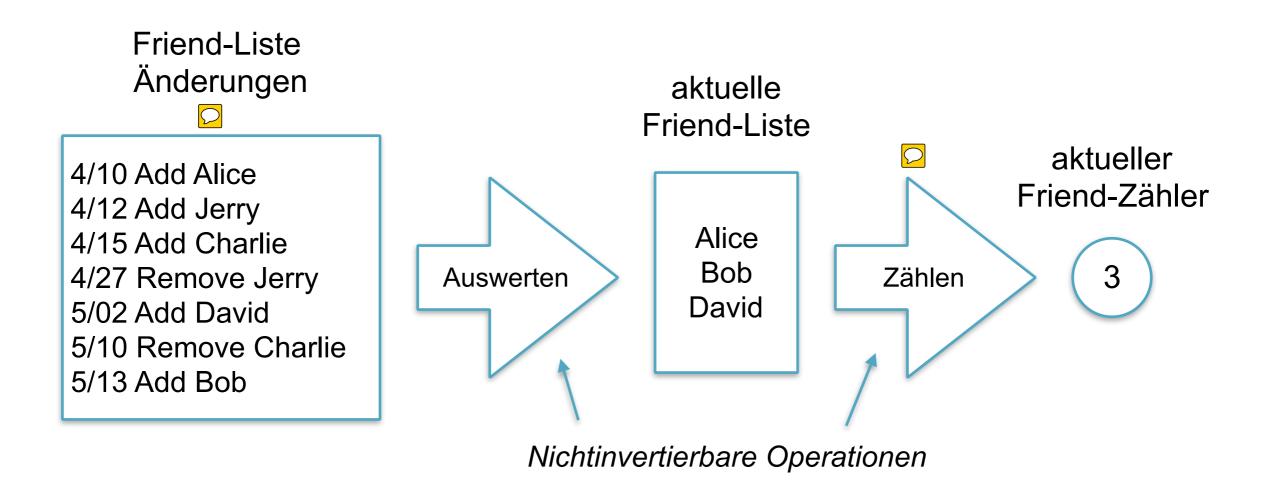
Daten sind Informationen, die nicht abgeleitet werden können

Queries sind Fragen, die mit den Daten beantwortet werden

Views sind Informationen, die von Basisdaten abgeleitet wurden. Sie unterstützen die Beantwortung bestimmter Arten von Fragen □



Ein Beispiel: Tom im sozialen Netzwerk

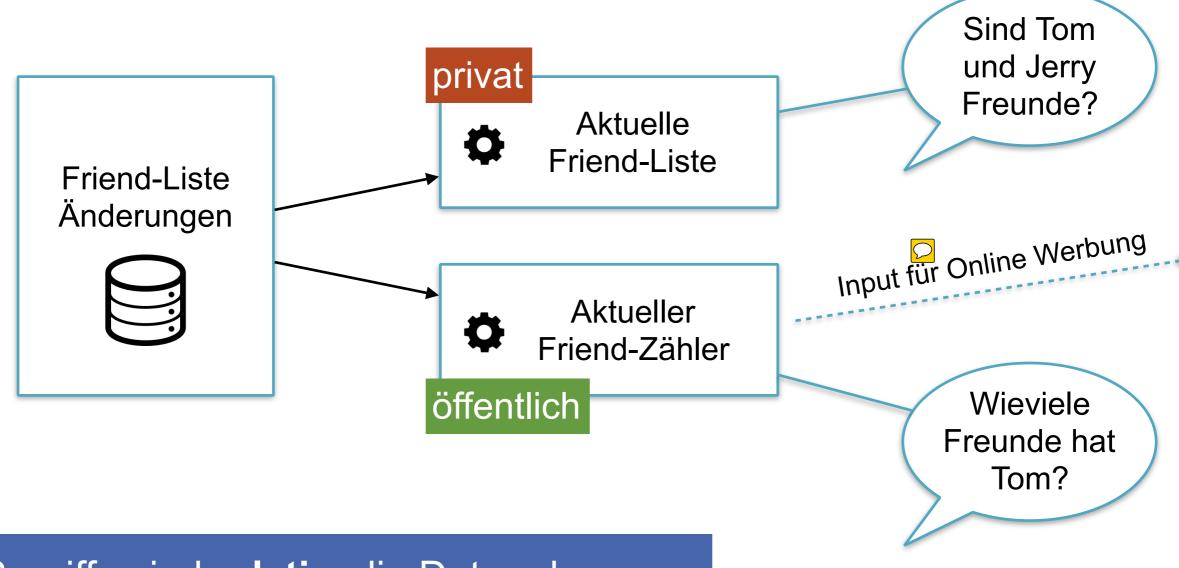


Jede Informationsebene kann aus der davor abgeleitet werden

Frage: Wo sind hier die Daten und wo die Views?



Data Views und Queries



Begriffe sind **relativ**: die Daten des einen können Views des anderen sein



Daten sind "roh" (raw)

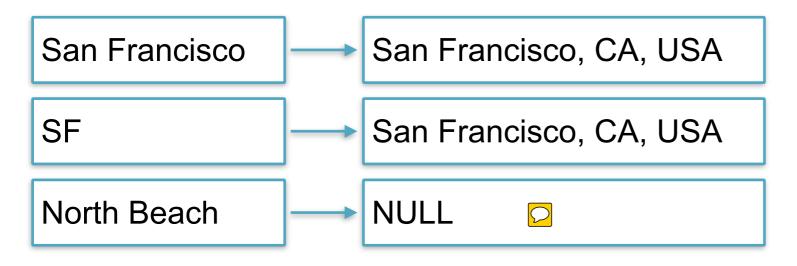
Daten sind **roh**, wenn sie ihre ursprüngliche Form haben und nicht verarbeitet wurden. Je **roher** die Daten, desto mehr Fragen kann das System beantworten.





Die richtigen Rohdaten auswählen

Unstrukturierte Daten sind roher als strukturierte Daten



Semantische Normalisierung Freiform Informationen in eine strukturierte Form umformen

Mehr Information führt nicht immer zu roheren Daten

- Annotierte Texteinträge sind rohere Daten als ASCII-Text-Strings
- HTML-Sourcen sind noch umfangreicher aber was nützt es?

Frage: was nützen die Annotationen (fett, kursiv, ...)?



Daten sind "unveränderbar" (immutable)

Unveränderbare Daten <u>nicht</u> ändern oder löschen, nur **hinzufügen** 🖸



- Menschliche Fehler erzeugen falsche Views, zerstören aber keine Daten. Views werden nach Korrektur einfach neu erzeugt
- Neue Daten hinzufügen statt überschreiben kein Index nötig

Daten unveränderbar machen: Attributtabellen mit **Zeitstempeln**

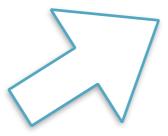
Immutable

Name da	Name data				
user id	name	timestamp			
1	Alice	2012/03/29 08:12:24			
2	Bob	2012/04/12 14:47:51			
3	Tom	2012/04/04 18:31:24			
4	Charlie	2012/04/09 11:52:30			

Age data			
user id age		timestamp	
1 25		2012/03/29 08:12:24	
2	36	2012/04/12 14:47:51	
3	28	2012/04/04 18:31:24	
4	25	2012/04/09 11:52:30	

Mutable

User	User information					
id	name	age	gender	employer	location	
1	Alice	25	female	Apple	Atlanta, GA	
2	Bob	36	male	SAS	Chicago, IL	
3	Tom	28	male	Google	San Francisco, CA	
4	Charlie	25	male	Microsoft	Washington, DC	



Location data			
user id	location	timestamp	
1	Atlanta, GA	2012/03/29 08:12:24	
2	Chicago, IL	2012/04/12 14:47:51	
3	San Francisco, CA	2012/04/04 18:31:24	
4	Washington, DC	2012/04/09 11:52:30	

Frage: was passiert wenn Tom nach LA zieht?



Daten sind "ewig wahr"

Unveränderbare Daten müssen ewig wahr bleiben. Ein Zeitstempel setzt Daten in Bezug zu ihrer Entstehungszeit.

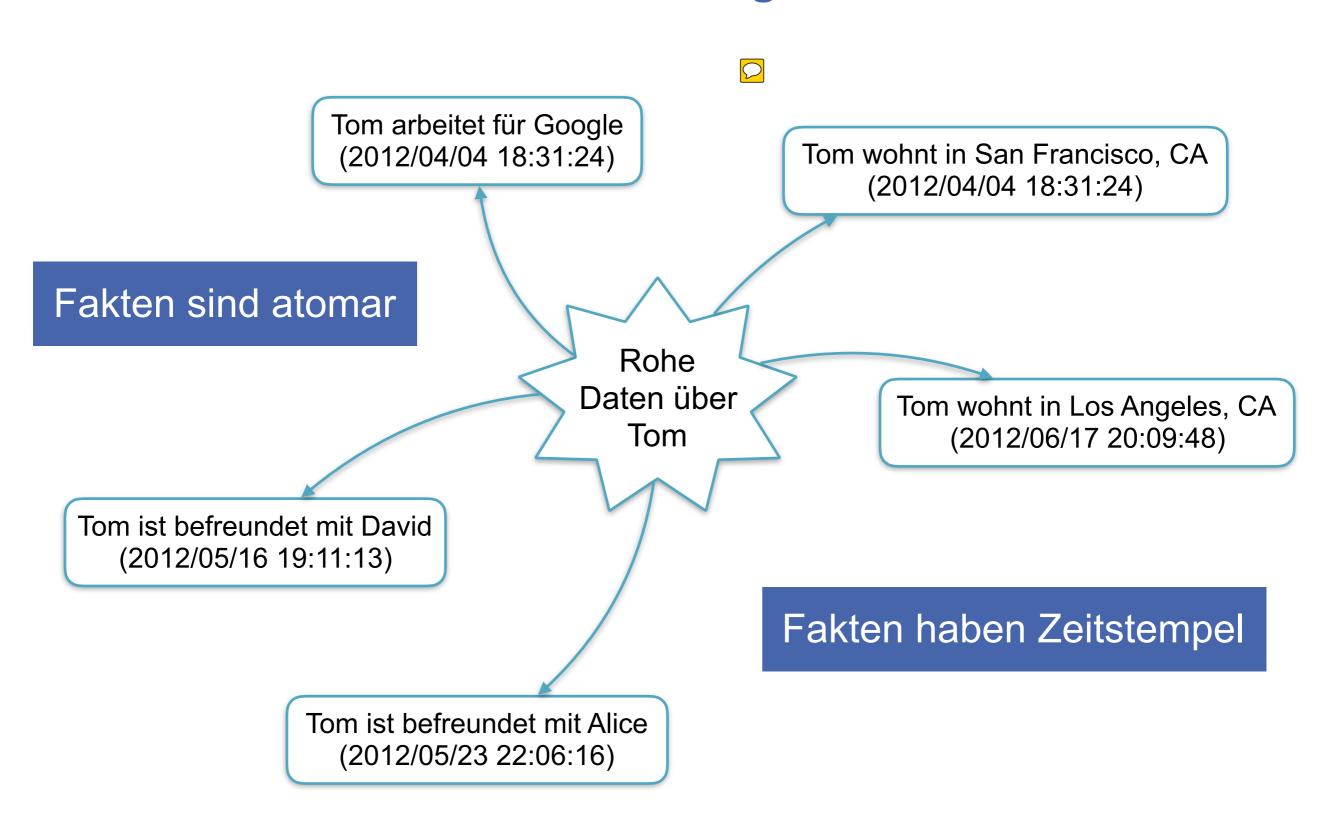
- Wahre Daten werden nie gelöscht außer bei…
 - Garbage Collection: die Daten haben zu wenig Wert. □
 - Regulation: die Daten dürfen nicht gespeichert werden. 🖸



Ein faktenbasiertes Datenmodell



Fakten sind atomar und zeitbezogen





Fakten sind identifizierbar

PageView Faktum V1

```
struct PageView:
DateTime timestamp
String url
String ip_address
```

Frage: Was passiert, wenn zwei Aufrufe zur gleichen Zeit von der gleichen IP kommen?

```
Struct PageView:

Datetime timestamp

String url

String ip_address

Long nonce
```

PageView Faktum V2



Fakten sind identifizierbar

PageView Faktum V1

```
struct PageView:
   DateTime timestamp
   String url
   String ip_address
```

Frage: Was passiert, wenn zwei Aufrufe zur gleichen Zeit von der gleichen IP kommen?

Struct PageView:

Datetime timestamp
String url
String ip_address
Long nonce

Ein **nonce** <u>identifiziert</u> ein Faktum; Duplikate werden erkannt und können bei der Verarbeitung gefiltert werden

 \bigcirc

PageView Faktum V2



Zusammenfassung

Das faktenbasierte Modell...

speichert Rohdaten als atomare Fakten

hält Fakten unveränderbar und ewig wahr durch Zeitstempel

macht Fakten mit nonce identifizierbar und Duplikaten erkennbar



Eigenschaften des faktenbasierten Modells

Die Masterdatenmenge ...

- ist für jeden Zeitpunkt seiner Geschichte abfragbar
 - Zeitstempel können bei der Abfrage berücksichtigt werden
- toleriert menschliche Fehler
 - Falsche Fakten werden (tatsächlich) gelöscht; die vorherige Version wird automatisch wirksam
- Kann mit partiellen Informationen umgehen
 - Fehlende Attribute erfordern keine NULL Werte, sondern es gibt einfach kein Faktum
- hat die Vorteile normalisierter und denormalisierter Formen
 - <u>Daten</u> sind normalisiert; <u>Views</u> können denormalisiert sein



Normalisierung

Datennormalisierung meint Daten in einer strukturierten Art zu speichern um Redundanz zu minimieren und Konsistenz zu fördern

Employment				
row id	name	company		
1	Bill	Microsoft		
2	Larry	BackRub		
3	Sergey (BackRub		
4	Steve	Apple		

Angestelltenliste denormalisiert mit Redundanz

User				Company	
user id	name	company id		company id	name
1	Bill	3		1	Apple
2	Larry	2	—	2	BackRuk
3	Sergey	2		3	Microsof
1	Steve	1		4	IBM

Angestellten- und Arbeitgeberlisten normalisiert ohne Redundanz



Graph Schemas

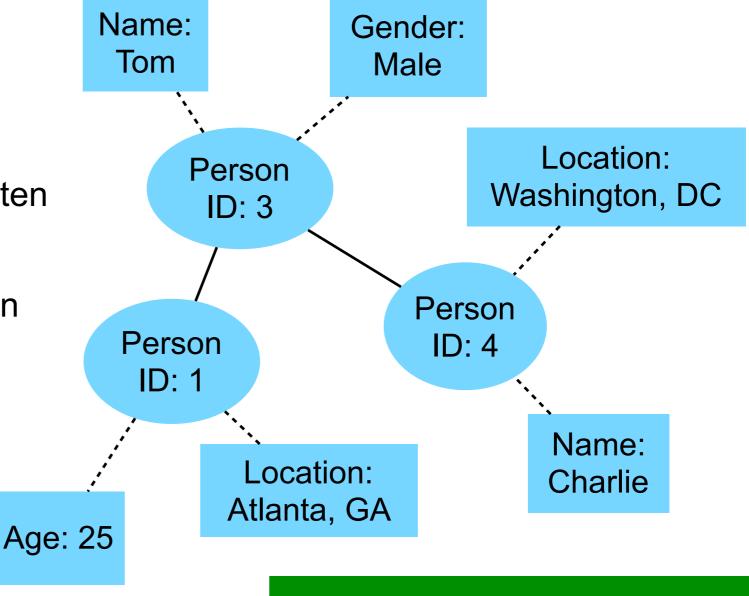




Struktur eines faktenbasierten Datensatzes

Fakten sind entweder Eigenschaften von Entitäten oder Beziehungen zwischen Entitäten. Ein Graph Schema repräsentiert Beziehungen zwischen Fakten und legt ihre Typen fest.

- Knoten Einheiten des Systems
- Kanten Beziehungen zwischen Knoten
- Eigenschaften Informationen über Einheiten



Frage: Wo sind die Fakten?



Struktur eines faktenbasierten Datensatzes

Fakten sind entweder *Eigenschaften* von Entitäten oder *Beziehungen* zwischen Entitäten. Ein **Graph Schema** repräsentiert Beziehungen zwischen Fakten und legt ihre Typen fest.

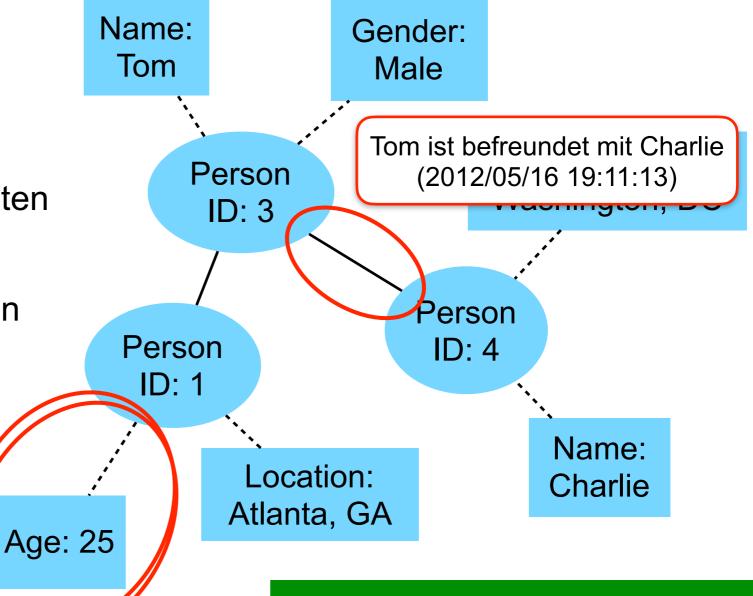
Knoten
Einheiten des Systems

Kanten
Beziehungen zwischen Knoten

Eigenschaften
Informationen über Einheiten

David ist 24 (2011/05/23 22:06:16)

David ist 25 (2012/05/23 22:06:16)



Frage: Wo sind die Fakten?



Struktur eines faktenbasierten Datensatzes

Das Graph Schema sollte **typgesichert** sein, um die Korrektheit von Fakten in der Masterdatenmenge zu garantieren.

```
"id": 3,
    "field":"age",
    "value":28,
    "timestamp": 1333589484
}
"id":2,
    "field":"age",
    "value":36
}
```

Verschiedene Fakten in validem JSON

```
"name":"Alice",
"field":"age",
"value":25,
"timestamp":"2012/03/29 08:12:24"
}
```



Apache Thrift



Apache Thrift

Thrift ist ein RPC Framework

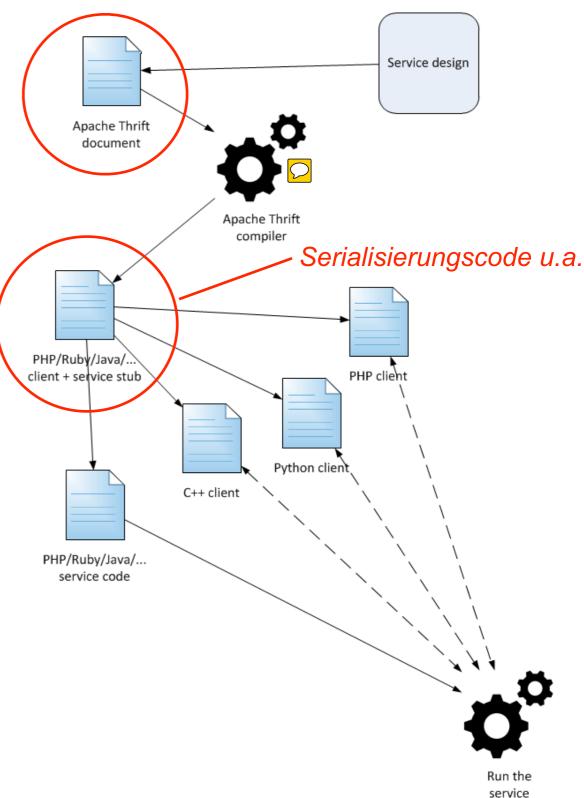
Von Facebook für "scalable crosslanguage services development" nun Open Source Apache Projekt

https://thrift.apache.org

Thrift IDL beschreibt Services und deren Datenschema

Thrift generiert aus IDL *Client* und *Server Stubs* in vielen Sprachen. Diese können Daten serialisieren, per Protokoll austauschen und wieder deserialisieren

Datenschema in Thrift IDL





Thrift Interface Definition Language (IDL)

Basistypen

- bool: boolean value (true or false), one byte
- byte: signed byte
- i16: 16-bit signed integer
- i32: 32-bit signed integer
- i64: 64-bit signed integer
- double: 64-bit floating point number
- binary: byte array
- string: encoding agnostic text or binary string

Container

- ■list<t1>: ordered list of elements
- set<t1>: unordered set of unique elements
- map<t1,t2>: map of unique keys



Thrift Interface Definition Language (IDL)

- enum: erstellt einen Aufzählungstyp mit Name-Wert-Paaren
- struct ist Kompositions- typ; Felder sind optional oder required und mit id identifiziert
- union: wie struct aber mit exakt einem Feld aus mehreren Alternativen
- typedef: erzeugt einen alternativen Namen für einen Typ.

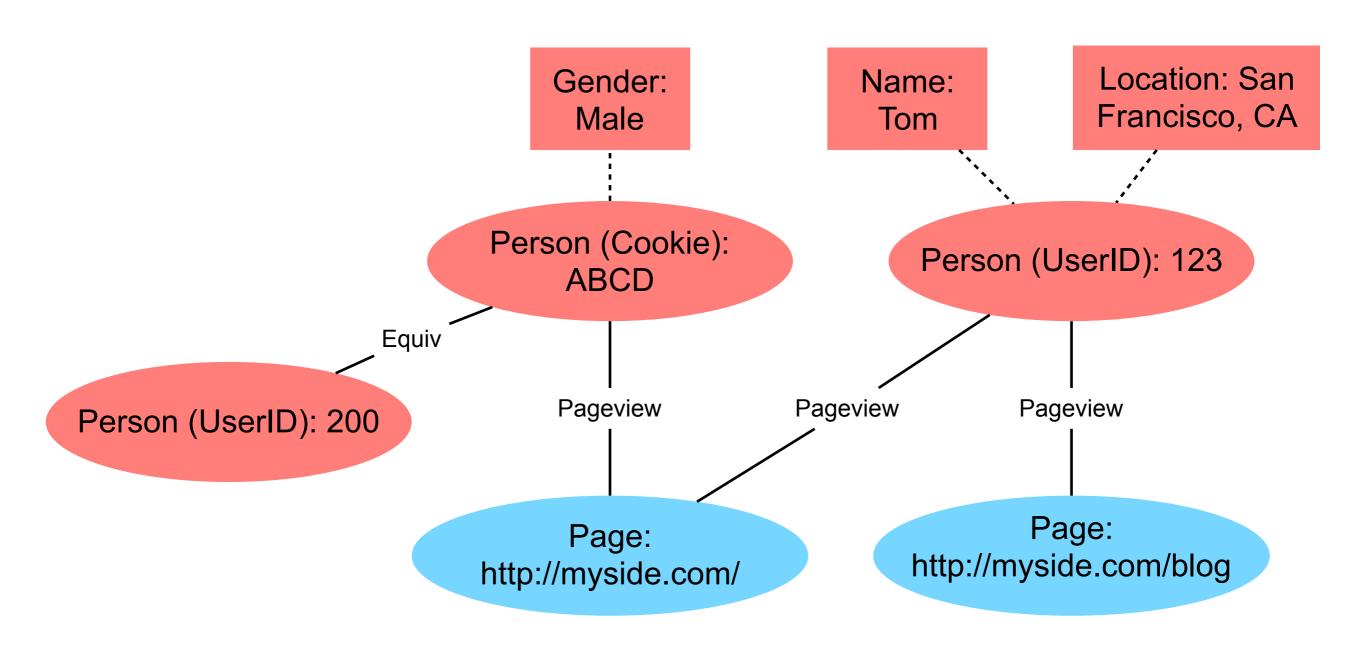
```
This is a valid comment.
* This is a multi-line comment.
// C++/Java style single-line comments work
enum TweetType {
   TWEET = 2,
   RETWEET
union TweetUser {
 i32 userId:
 string userName;
struct Tweet {
   1: required TweetUser;
  2: required string text;
    3: optional Location loc;
    4: optional TweetType tweetType = TweetType.TWEET
   16: optional string language = "english"
typedef Tweet ReTweet
```



Graph Schema Implementierung mit Thrift



SuperWebAnalytics Graph Schema Beispiel





Thrift Graph Schema für SuperWebAnalytics

```
union PersonID {
                                   enum GenderType {
   1: string cookie;
                                     MALE = 1,
   2: i64 user id;
                                     FEMALE = 2
                                   union PersonPropertyValue {
 union PageID
                                     1: string full name;
   1: string url;
                                     2: GenderType gender;
                                     3: Location location;
 struct Location |
   1: optional string city;
   2: optional string state;
                                   struct PersonProperty {
    3: optional string country;
                                     1: required PersonID id;
                                     2: required PersonPropertyValue property;
```

Knoten und Eigenschaften

- Personen (PersonID) sind durch ID oder Cookie repräsentiert
- PersonProperty verbindet Personen mit einer alternativen Eigenschaft (PersonPropertyValue)
- Ortsinformationen (Location) sind kohäsiv (zusammenhängend)



Thrift Graph Schema für SuperWebAnalytics

```
struct EquivEdge {
   1: required PersonID id1;
   2: required PersonID id2;
}

struct PageViewEdge {
   1: required PersonID person;
   2: required PageID page;
   3: required i64 nonce;
}
```

```
struct Pedigree {
   1: required i32 true_as_of_secs;
}
union DataUnit {
   1: PersonProperty person_property;
   2: EquivEdge equiv;
   3: PageViewEdge page_view;
}
struct Data {
   1: required Pedigree pedigree;
   2: required DataUnit dataunit;
}
```

Kanten

Datentypen für Fakten

- PageViewEdge Kanten sind identifizierbar (nonce)
- Metadaten (Pedigree) sind mindestens Zeitstempel (erweiterbar)
- Fakten (Data) sind Änderungen von Kanten oder Eigenschaften



Thrift Graph Schema Evolution

```
struct EquivEdge {
   1: required PersonID id1;
   2: required PersonID id2;
}

struct PageViewEdge {
   1: required PersonID person;
   2: required PageID page;
   3: required i64 nonce;
}

struct LinkEdge {
   1: required PageID id1;
   2: required PageID id2;
}
```

```
struct Pedigree {
 1: required i32 true as of secs;
  2: optional string source;
union DataUnit {
  1: PersonProperty person property;
 2: EquivEdge equiv;
 3: PageViewEdge page view;
  4: LinkEdge link;
struct Data {
 1: required Pedigree pedigree;
 2: required DataUnit dataunit;
```

Neue Kanten

Neue Fakten und Metadaten

- Knoten hinzufügen ist kein Problem
- Felder hinzufügen ist ok; müssen aber optional sein
- Felder löschen auch möglich; Feld-ID dann aber nicht mehr nutzbar



Zusammenfassung und Ausblick



Heute haben wir...

- ... die Eigenschaften von Daten untersucht
- Daten faktenbasiert modelliert
- Fakten durch Graph Schemas strukturiert
- Graph Schemas mit Thrift implementiert

Als nächstes wollen wir...

- untersuchen
- Daten in HDFS persistent speichern



Literatur und Links

- Nathan Marz, James Warren, "Big Data: Principles and best practices of scalable realtime data systems", Manning, 2015, Kapitel 2+3
- Mark Slee, Aditya Agarwal and Marc Kwiatkowski, "Thrift: Scalable Cross-Language Services Implementation", Whitepaper, Facebook, 2007 https://thrift.apache.org/static/files/thrift-20070401.pdf
- Diwaker Gupta, "Thrift: The Missing Guide" http://diwakergupta.github.io/thrift-missing-guide/